29 DE DICIEMBRE DE 2020

BASES DE DATOS NO SQL

MONGO DB

PABLO MARIA CASERO PALMERO

UCM

[Dirección de la compañía]

1. Exploración de los datos

En primer lugar, hablaré de la fuente datos de la que me he servido para el análisis de los datos a través de una base datos NoSQL.

1.1.Análisis exploratorio de los datos

El conjunto de datos procede de una fuente de bases datos web https://www.kaggle.com/acerca de las ratios de suicidio acontecidos entre 1985 y 2016 a lo largo de una serie de países, donde se incluyen factores socioeconómicos que puedan influir en una mayor tasa de suicidios.

El archivo csv se denomina master.csv y contempla *12 columnas* con un total de *27819 entradas*. Dicho dataset contiene información del tipo:

VARIABLES	TIPO	DESCRIPCIÓN
Country	String	País
Year	Integer	Año
Sex	String	Sexo
Age	Integer	Edad
Suicides_no	Integer	Número de suicidios
Population	Integer	Población
Suicides/100k pop	Decimal	Ratios suicidios por cada 100 mil habitantes
Country-year	String	País-año
HDI for year	Decimal	Índice de desarrollo humano
Gdp_for_year	String	Producto Interior Bruto por año
Gdp_per_capita	Integer	Producto Interior Bruto per cápita
Generation	String	Media de años agrupada

1.2.Importación del dataset a NoSQL

La importación ha sido realizada manualmente a través del cliente **NoSQL Booster MongoDB**, debido a los numerosos problemas ocasionados al realizarlo a través de un ejecutable .bat . Una vez realizada con éxito tenemos lo siguiente:

La colecciónde datos se llama master y se lleva a cabo desde un servidor local alojado en un bbdd denominado prueba.

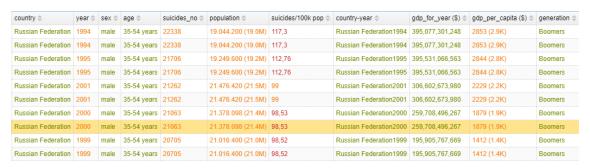
2. Ejercicios sobre inserción, actualización, proyección y filtrado

A continuación, expondré una querys a modo de visualizar la información que tenemos en el database. Al cargar los datos, tenemos unos 55649 documentos dentro de nuestra colección llamada 'master', donde internamente tendremos unos 12 campos definidos con su entidad y clave según del documento se trate con su clave correspondiente

2.1. Número de suicidios y tasa de suicidios por cada 100 K habitantes:

Al tratarse de una información que gira en torno al número de suicidios en diferentes países me interesa saber de primera mano quién es que mayor número presenta. Es importante bajo que escala de comparación lo hacemos. Por ejemplo:

Si bien hago una query sobre los diez primeros países con mayor número de suicidios obtengo:



Como país resultante rusia con un número máximo de 22338 entre hombre de 35-54 años en el año 1994. Si bien nos parecerá alto, pero comparado al nivel de población entonces 19044200 no es un porcentaje tan alto. También nos está diciendo que con el paso de los años ha seguido manteniendo el mayor número, aun mejorando con el paso de los años.

Esto no es una buena manera de enfrentar los datos dado que según sea el volumen de población en unos u otros parecerá haber mayor o menor número de suicidios. Por tanto, lo mejor es fijarse en la tasa de suicidios por cada 100 mil habitantes, que es un estándar que permitirá comparar de una mejor manera los datos en relación con el número de suicidios y población objetos de estudio.

El código para este caso es:

```
// Mostrar toda la información de los diez entradas con el mayor número de suicidios por cada 1000 habitantes
var opcion= { "suicides/100k pop" : -1 }
db.master.find().sort(opcion).limit(10)
```

La tabla resultante es:

country \$	year 📥	sex 🗢	age \$	suicides_no \$	population \$	suicides/100k pop \Leftrightarrow	country-year \$	gdp_for_year (\$) \Rightarrow	gdp_per_capita (\$) \$	generation \$	HDI for year \$
Aruba	1995	male	75+ years	2	889	224,97	Aruba1995	1,320,670,391	17.949 (17.9K)	G.I. Generation	
Aruba	1995	male	75+ years	2	889	224,97	Aruba1995	1,320,670,391	17.949 (17.9K)	G.I. Generation	
Seychelles	2006	male	75+ years	2	976	204,92	Seychelles2006	1,016,418,229	12.442 (12.4K)	Silent	
Seychelles	2006	male	75+ years	2	976	204,92	Seychelles2006	1,016,418,229	12.442 (12.4K)	Silent	
Republic of Korea	2010	male	75+ years	1152	631.853 (0.63M)	182,32	Republic of Korea2010	1,094,499,338,703	22.994 (23.0K)	Silent	
Republic of Korea	2010	male	75+ years	1152	631.853 (0.63M)	182,32	Republic of Korea2010	1,094,499,338,703	22.994 (23.0K)	Silent	
Republic of Korea	2011	male	75+ years	1276	688.365 (0.69M)	185,37	Republic of Korea2011	1,202,463,682,634	25.157 (25.2K)	Silent	
Republic of Korea	2011	male	75+ years	1276	688.365 (0.69M)	185,37	Republic of Korea2011	1,202,463,682,634	25.157 (25.2K)	Silent	
Suriname	2012	male	75+ years	10	5346 (5.3K)	187,06	Suriname2012	4,980,000,000	10.227 (10.2K)	Silent	0.711
Suriname	2012	male	75+ years	10	5346 (5.3K)	187,06	Suriname2012	4,980,000,000	10.227 (10.2K)	Silent	0.711

De esta forma, encontramos mayor variabilidad entre los países resultantes, años y población. Es interesante que pese a que Aruba presente pocos suicidios en el año 1995, su tasa de suicidios es altísima dado su bajo nivel de población. A simple vista son países pequeños, quizás con no tan alto nivel de riqueza (exceptuando a Korea).

2.2. Influencia con el paso de los años en la tasa de suicidios

Una buena manera de analizar los datos sería la evolución en el tiempo

Nota: el orden esta fijado según la id que en este caso es la variable años

```
// Evolución de la tasa de suicidios por año ordenador de manera secuencial
var query1 = { "_id": {year:"$year"}, rate: { $sum: "$suicides/100k pop" }}
var fase1 = { $group: query1 }
var query2= { "_id": 1 }
var fase2 = { $sort: query2 }
var etapas = [ fase1, fase2 ]
db.master.aggregate( etapas )
```

La tabla así lo muestra:

	_id	rate 🔷			
1		13.623,78 (13.6K)	16	☑ { year : 2000 }	28.774,9 (28.8K)
2		13.159,68 (13.2K)	17		28.552,42 (28.6K)
3		15.090,9 (15.1K)	18		28.455,44 (28.5K)
4		14.946,26 (14.9K)	19		27.255,16 (27.3K)
5		16.073,08 (16.1K)	20		25.163,6 (25.2K)
6	☑ { year : 1990 }		21		24.329,98 (24.3K)
7		20.642,12 (20.6K)	22	☑ { year : 2006 }	24.332,02 (24.3K)
			23	☑ { year : 2007 }	24.820,3 (24.8K)
8		21.057,76 (21.1K)	24	🖸 { year : 2008 }	24.291,68 (24.3K)
9		21.580,58 (21.6K)	25		24.352,08 (24.4K)
10	☑ { year : 1994 }	22.967,58 (23.0K)	26	☑ { year : 2010 }	23.687,98 (23.7K)
11		29.320,52 (29.3K)	27	🖸 { year : 2011 }	22.735,68 (22.7K)
12	☑ { year : 1996 }	28.284,42 (28.3K)	28	🖸 { year : 2012 }	22.203,82 (22.2K)
13		27.635,66 (27.6K)	29		21.327,28 (21.3K)
14		28.301,44 (28.3K)	30		20.613,46 (20.6K)
15	🖸 { year : 1999 }	28.947,82 (28.9K)	31		16.507,98 (16.5K)
16	🖸 { year : 2000 }	28.774,9 (28.8K)	32		4294,78 (4.3K)

La tasa de suicidios sube notablemente habiendo pasado unos diez años desde el primer año recogido (1985), con fuerte subidas en el 95,96. Después se estabiliza y comienza a bajar las tasas suavemente. Por lo que se ve se ha logrado revertir la situación de la alta incidencia de casos de suicidios en los años más cercanos a la actualidad, situándose en 2015 en niveles de 1987.

2.3. Agrupación por países del número de suicidios según el género

En este punto, empleamos los datos de forma agregada, lo que permitirá categorizarlos según como queramos estructurar los datos.

Primero, vemos su agrupación por países. En el código plasmamos y nos sale JSON:

```
// contabilizar el número de suicidios por país |
var query1 = { "_id": "$country", "suicides_no": { $sum: 1 } } {
var fase1 = { $group: query1 }
var etapas = [ fase1 ]
db.master.aggregate(etapas)
},
"_id": "Maldives",
"suicides_no": 240
```

Podemos mejorar la categorización para dar un punto de vista más detallado:

```
// Agrupar por sexo y edad y hallar el número de suicidios

var query1 = { "_id": {sex: "$sex", age:"$age"}, count: {$sum: 1 } }

var fase1 = { $group: query1 }

db.master.aggregate( fase1 )
"_id": {
    "sex": "male",
    "age": "15-24 years"
},
    "count": 4642
```

Esto pinta mejor a la hora de interpretar los datos. Si bien mediante uno de los campos es country-year que engloba a dos columnas, los campos de sexo y tasa de suicidios por cada 100K, concentramos la información de forma más detallada y cercando el número de posibilidades. Con esta información el código que resulta:

```
// Hallar el máximo de suicidios y sacar la ciudad y el año y el sexo en que se produjeron de manera ordenada de
var query1 = { "_id": {country_year:"$country-year", gender:"$sex"}, max_rate: { $max: "$suicides/100k pop" }}
var fase1 = { $group: query1 }
var query2= { "max_rate" : -1 }
var fase2 = { $sort: query2 }
var etapas = [ fase1, fase2 ]
db.master.aggregate( etapas )
```

El documento que saldría de esta query sería:

```
/* 1 */
                                                             Sigue apuntando a que Aruba en 1996
     "_id" : {
    "country_year" : "Aruba1995",
    "gender" : "male"
                                                             aconteció el mayor número de suicidios a
                                                             nivel mundial
      max rate" : 224.97
},
/* 2 */
                                                                                      Value 
      _id" : {
                                                    ■ [iii] (1) { country_year : "Aruba1995", ge { max_rate : 224.97 }
         "country_year" : "Seychelles2006",
"gender" : "male"
                                                       ▶ € ] _id
                                                                                      { country_year : "Aruba1995", gender : "male" }
                                                        i max_rate
     'max_rate" : 204.92
```

Otra vuelta que podríamos hacer con relación a un tipo de sexo y al país proveniente de los datos :

```
// Agrupar por países el número de suicidios entre únicamente los hombres y ordenados de manera descendiente
var query1 = { "sex": "male" }
var fase1 = { $match: query1 }
var query2 = { "_id": "$country", "suicides_no": { $sum: "$suicides_no" } }
var fase2 = { $group: query2 }
var fase3 = {$sort:{"suicides_no":-1}}
var etapas = [ fase1,fase2, fase3]
db.master.aggregate( etapas )
```

Hombres Mujeres

	_id	suicides_no 🗢		_id	suicides_no 🗢
1	Russian Federation	1990824	1	Japan	503260
2	United States	1640432	2	Russian Federation	428660
3	Japan	1110544	3	United States	427594
4	Ukraine	517146	4	France	178838
5	France	479416	5	Republic of Korea	165230
6	Germany	423110	6	Germany	159414
7	Republic of Korea	358230	7	Ukraine	122754
8	Brazil	355196	8	Brazil	98030
9	Poland	236070	9	Italy	65762
10	United Kingdom	208236	10	United Kingdom	65374

Este resumen por sexo del número de suicidios en los distintos países nos hacen ver que pueda haber similitud de casos ocurridos en un pais (Alemania se sitúa en el mismo lugar en ambos casos). Cierto es que en el top 3 se alternan puestos tanto en hombres y mujeres, también que hay países que aparezcan en el top ten en hombres y no mujeres (caso de Polonia)

2.4. Estudio estadístico en cifras por países, sexo, edad

Si bien podemos analizar estadísticamente los valores recogidos en el dataset para ver cómo están distribuidos y sintetizados.

```
// calcular la media ,la desviación típica, mínimo, máximo de tasa de suicidios por cada país
var query1 = { "_id": {country:"$country"}, mean_rate: {$avg: "$suicides/100k pop" }, min_rate: {$min: "$suicides/100k pop"},
max_rate: {$max: "$suicides/100k pop"}, std: {$stdDevSamp:"$suicides/100k pop" }}
var fase1 = { $group: query1 }
var etapas = [ fase1 ]
db.master.aggregate( etapas )
var query1 = { "_id": "suicides/100k pop", mean_rate: {$avg: "$suicides/100k pop" }}
db.master.aggregate( query1 )
```

La visualización en tabla ayuda a entender mejor los datos:

	_id	mean_rate 🕶	min_rate \$	max_rate \$	std 🌲
1		40,4156	0	151,33	39,1916
2	☑ { country : "Sri Lanka" }	35,2952	0,66	125,22	30,5115
3		34,8924	0,44	117,3	33,1803
4		32,7615	0	177,61	37,972
5	{ country : "Belarus" }	31,0759	0,22	107,15	31,0498
6	☑ { country : "Latvia" }	29,2593	0	118,84	30,1022
7		27,8279	0	144,71	30,7808
8		27,2769	0	125,46	29,0804
9		26,5823	0,16	96,42	26,2684
10		25,1356	0,2	185,37	33,3851

Ahora los datos hacen indicar que Lituania en promedio es la que mayor tasa de suicidios presenta a lo largo de los años entre hombres y mujeres. También, que en general en países nórdicos o situados al este de Europa presentan un alto índice de suicidios, aunque Sri Lanka rompa con esa tendencia situándose en segundo lugar. Hay que comentar que hay bastante disparidad entre los datos dado que se han anotado picos medios de tasa de suicidios, donde Aruba ahora la sitúan e 53º lugar entre todos los países.

Viendo que el factor sexo juega un papel importante también. Veamos como es el porcentaje entre hombre y mujeres. Para ello, necesito ver el total de la suma del número de suicidios entre hombres y mujeres en conjunto

```
var total_rate = db.master.aggregate({ "$group": { "_id": {}, "total":{$sum: "$suicides_no" }}})
```

El cual no da un total de 1349684. Con ello podemos ver la distribución en porcentaje. El código es interesante de analizar, sabiendo primero que debo agrupar por sexo

El porcentaje que sale es:



Los datos evidencian que en el caso de los hombres se dan un mayor número de casos de hasta un 76% del total de los casos en contraposición al de las mujeres. Esto también es aplicable a la categorización por edades

	_id	total_ages \$	percentage \$
1		1.306.236 (1.3M)	9.6%
2		104.528 (0.10M)	0.7%
3		1.617.084 (1.6M)	11.%
4		4.904.282 (4.9M)	36.%
5		3.316.886 (3.3M)	24.%
6		2.247.824 (2.2M)	16.%

Esta tabla arroja a la luz algo que un principio no creímos que fuera posible. Con lo anteriormente obtenido todo hacía indicar que las personas mayores de 75 eran las que mayor número presentaban. Pues como vemos, los datos dicen lo contrario hasta situarlo en un porcentaje del 9.6%, mientras que el rango donde situaríamos a la mayoría de la población es de 36% de los casos de suicidios en el mundo.

2.5. Relación socioeconómica del número de suicidios

Echemos un vistazo a las variables económicas y su posible relación con el número de suicidios.

La variable *HDI for year* (Indice de desarrollo Humano) presenta valores vacíos y nos interesaría saber qué países presentan ese indicador.

```
db.master.distinct("country",{"HDI for year":{$exists:true}} ).length
```

Finalmente obtenermos unos 90 documentos que contienen ese campo . podemos actualizar los campos ausentes para contabilizarlos mediante un update:

```
// Actualicemos los campos donde no exista el campo HDI y sistituyámoslos por el valor 'desconocido'
db.master.update({'HDI for year': {$exists : false}}, {$set: {'HDI for year': 'unknown'}})
```

con ello podemos esclarecer mejor la información que nos aporta el dataset.

Para ver si los factores socioeconómicos y número de casos de suicidios estan relacionados, he establecido una query que agrupe por países sus ratios de *suicidios* y *gdp per cápita* por cada uno de ellos. Posteriormente he establecido una serie de condiciones si supera los indicadores medios tanto de suicidios como de nivel económico. El código entraña una serie de condiciones fuera del agrupamiento marcando 1 como true y 0 false. Previamente habremos obtenido el promedio total de los países por cada indicador

La tabla final es muy interesante:

	_id \$	sper100k_mean_rate \$	gdp_mean \$	suicide_rate 🕶	gdp_rate \$	all \$
1	{ country : "Macau" }	14,3117	18.081 (18.1K)	1	1	1
2	{ country : "New Zealand" }	14,3917	22.279,4828 (22.3K)	1	1	1
3	(country: "Belgium")	21,2379	32.066,7419 (32.1K)	1	1	1
4	(country: "Singapore")	17,0456	38.050,2581 (38.1K)	1	1	1
5	{ country : "United States" }	13,8198	39.269,6129 (39.3K)	1	1	1
6	{ country : "Norway" }	12,941	57.319,6 (57.3K)	1	1	1
7	{ country : "Denmark" }	14,0972	49.299,9091 (49.3K)	1	1	1
8	(country: "Austria" }	23,7598	34.261,7801 (34.3K)	1	1	1
9	{ country : "Luxembourg" }	16,5499	68.798,3871 (68.8K)	1	1	1
10	(country: "Sweden")	14,6584	41.357,5754 (41.4K)	1	1	1
11	(country: "Australia")	12,9928	32.776,4 (32.8K)	1	1	1
12	(country: "Slovenia")	27,8279	18.642,2381 (18.6K)	1	1	1
13		21,6757	31.481,4667 (31.5K)	1	1	1
14	{ country : "Japan" }	21,5732	36.397,5484 (36.4K)	1	1	1
15	(country: "Finland" }	22,7704	35.468,2759 (35.5K)	1	1	1

Si los ordenamos de mayor a menor por la tasas de suicidios tenemos que:

	_id	sper100k_mean_rate <	gdp_mean \$	all 🕏
1	{ country : "Lithuania" }	40,4156	9280,5496 (9.3K)	0
2		35,2952	904,2727	0
3	{ country : "Russian Federation" }	34,8924	6518,8148 (6.5K)	0
4		32,7615	9370,0516 (9.4K)	0
5		31,0759	3333,9048 (3.3K)	0
6		30,5113	5329,1154 (5.3K)	0
7	☑ { country : "Latvia" }	29,2593	8961,0952 (9.0K)	0
8	{ country : "Slovenia" }	27,8279	18.642,2381 (18.6K)	1
9		27,2769	11.376,0952 (11.4K)	0
10		26,5823	1867,5357 (1.9K)	0
11	{ country : "Republic of Korea" }	25,1356	14.801,2581 (14.8K)	0
12		23,7598	34.261,7801 (34.3K)	1
13	{ country : "Croatia" }	22,8353	10.355,8702 (10.4K)	0
14	{ country : "Finland" }	22,7704	35.468,2759 (35.5K)	1
15		22,1864	1674,92 (1.7K)	0
16		22,1641	4471,2778 (4.5K)	0
17	<pre> { country : "France" } </pre>	21,6757	31.481,4667 (31.5K)	1
18		21,5732	36.397,5484 (36.4K)	1
19	☑ { country : "Suriname" }	21,3164	4351,9643 (4.4K)	0
20		21,2379	32.066,7419 (32.1K)	1

Tenemos que no necesariamente un alto indice de suicidios implica que tenga lugar en países con mayor renta per capita del mundo, lo que no hay una correlación directa entre ambas variables. Si de otro modo situamos a los países con mayor capacidad económica es posible ver que se den más casos donde se supere la media de tasa de suicidios por cada 100 mil habitantes

3. Resumen final

Como conclusión, podemos decir que no necesariamente en países ricos se dan los mayores casos de suicidios, aunque mantengan una tendencia alta sobre todo en los años más recientes. Es cierto que anteriormente los niveles de suicidio son todavía muy altos con respecto a los de la actualidad. La relación entre un mayor número de casos y el nivel de riqueza es perceptible en países del norte con altos niveles de riqueza y tasas de suicidio. Aunque, los países del este rompen con esa regla dado que no mantienen los mismos niveles de riqueza. El factor del sexo si que es influyente en nuestro estudio, dado que claramente ocurre en hombres hasta en un 76% casos y donde la edad se extiende en distintos rangos de población donde 34-50 años recoge el mayor número de casos.